Эконометрика. Конспект лекций и семинаров

Личный учебный конспект: линейная регрессия, проверка гипотез, нарушения предпосылок, инструменты, бинарный выбор, временные ряды и панели

1. Предмет эконометрики и типы данных

Эконометрика — это раздел, в котором экономическая теория, статистика и вычисления соединяются для того, чтобы оценивать количественные связи между показателями и проверять гипотезы о них на реальных данных. Теория обычно говорит только о направлении связи: если цена растёт, спрос падает. Эконометрика пытается ответить на вопрос «насколько»: на сколько процентов упадёт спрос при росте цены на один процент, и насколько мы уверены в этой оценке.

Типичная последовательность работы выглядит так. Сначала формулируется содержательная гипотеза. Затем выбирается спецификация модели, то есть набор переменных и функциональная форма. Потом собираются данные, модель оценивается, проверяются предпосылки, и только после этого результаты интерпретируются. Если предпосылки нарушены, модель исправляют и цикл повторяется. На практике самая долгая часть — не оценивание, а проверка и исправление спецификации.

Выделяют три основных типа данных.

- Пространственные (cross-section) данные: много объектов в один момент времени. Например, зарплаты 2000 работников в 2025 году. Порядок наблюдений здесь не важен, наблюдения обычно считают независимыми.
- Временные ряды: один объект в разные моменты времени. Например, ежемесячный курс валюты за 10 лет. Порядок важен, соседние наблюдения обычно зависимы.
- Панельные данные: много объектов, каждый из которых наблюдается в несколько моментов времени. Например, 80 регионов за 15 лет. Такие данные позволяют учитывать ненаблюдаемые различия между объектами.

Отдельно стоит помнить разницу между корреляцией и причинностью. Регрессия сама по себе показывает условное среднее одной переменной при заданных значениях других. Причинная интерпретация коэффициента требует дополнительного аргумента: что все существенные факторы учтены или что используется источник экзогенной вариации, например инструментальная переменная или естественный эксперимент.

2. Парная линейная регрессия

2.1. Постановка модели

Рассматривается модель

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i,\ i = 1, \ldots, n.$$

Здесь y_i — зависимая (объясняемая) переменная, x_i — регрессор (объясняющая переменная), β_0 и β_1 — неизвестные параметры, ε_i — случайная ошибка. Ошибка собирает в себе всё, что влияет на y, но не вошло в модель: пропущенные факторы,

ошибки измерения, чистую случайность.

Важно различать ошибку ε_i и остаток e_i. Ошибка ненаблюдаема, потому что неизвестны истинные β. Остаток — это разница между фактическим и предсказанным значением после оценивания: $e_i = y_i - \hat{y}_i$.

2.2. Метод наименьших квадратов

Метод наименьших квадратов (МНК, OLS) выбирает оценки b_0 и b_1 так, чтобы минимизировать сумму квадратов остатков:

$$S(b_0, b_1) = \sum (y_i - b_0 - b_1 x_i)^2 \to \min.$$

Приравниваем частные производные к нулю:

$$\frac{\partial S}{\partial b_0} = -2 \sum (y_i - b_0 - b_1 x_i) = 0,$$
$$\frac{\partial S}{\partial b_1} = -2 \sum x_i (y_i - b_0 - b_1 x_i) = 0.$$

Это система нормальных уравнений. Из первого уравнения получаем $\bar{y} = b_0 + b_1 \bar{x}$, то есть линия регрессии проходит через точку средних. Подставляя $b_0 = \bar{y} - b_1 \bar{x}$ во второе уравнение, получаем

$$b_1 = \sum (x_i - \bar{x})(y_i - \bar{y}) \,/\, \sum (x_i - \bar{x})^2 = \operatorname{cov}(x, y) \,/\, \operatorname{var}(x),$$
$$b_0 = \bar{y} - b_1 \bar{x}.$$

Из нормальных уравнений сразу следуют два полезных свойства остатков: $\sum e_i = 0$ (если в модели есть константа) и $\sum x_i e_i = 0$, то есть остатки некоррелированы с регрессором. Кроме того, среднее предсказанных значений совпадает со средним фактических.

Замечание из практики: если убрать константу из модели, сумма остатков уже не обязана быть нулевой, и обычный R^2 может оказаться отрицательным или потерять смысл. Поэтому константу оставляют почти всегда, даже если теория говорит, что она должна быть равна нулю.

2.3. Интерпретация коэффициентов

Коэффициент b_1 показывает, на сколько единиц в среднем изменится y при увеличении x на одну единицу. Константа b_0 — это прогноз y при $x = 0$. Константу часто нельзя интерпретировать содержательно: например, если x — площадь квартиры, то квартира площадью ноль квадратных метров не существует.

Пример. Пусть оценена модель зарплаты (тыс. руб.) от стажа (лет): $\hat{y} = 42{,}3 + 3{,}1 \cdot \text{стаж}$. Интерпретация: каждый дополнительный год стажа в среднем связан с ростом зарплаты на 3,1 тыс. руб. Слово «связан» здесь важно: без дополнительных аргументов это не обязательно причинный эффект.

2.4. Разложение дисперсии и коэффициент детерминации

Общая сумма квадратов раскладывается на объяснённую и остаточную:

$$TSS = \sum (y_i - \bar{y})^2,\quad ESS = \sum (\hat{y}_i - \bar{y})^2,\quad RSS = \sum e_i^2,$$
$$TSS = ESS + RSS.$$

Равенство выполняется при наличии константы, потому что перекрёстное слагаемое $2\sum(\hat{y}_i - \bar{y})e_i$ обращается в ноль благодаря нормальным уравнениям.

Коэффициент детерминации

$$R^2 = ESS / TSS = 1 - RSS / TSS$$

показывает долю вариации y, объяснённую моделью. В парной регрессии R^2 равен квадрату выборочного коэффициента корреляции между x и y.

Высокий R^2 не означает, что модель хорошая, а низкий — что плохая. В пространственных данных о поведении людей $R^2 = 0{,}15$ может быть вполне нормальным, а в регрессии одного трендового временного ряда на другой $R^2 = 0{,}98$ может оказаться ложной регрессией. Смотреть надо на цель: для прогноза R^2 важен, для оценки эффекта важнее несмещённость коэффициента.

3. Свойства МНК-оценок

3.1. Условия Гаусса–Маркова

Классическая линейная модель регрессии опирается на набор предпосылок:

- Линейность по параметрам: $y = \beta_0 + \beta_1 x + \varepsilon$. Нелинейность по переменным допустима, например $y = \beta_0 + \beta_1 \ln x + \varepsilon$ — это всё ещё линейная модель.
- Случайная выборка или фиксированные регрессоры.
- Отсутствие строгой мультиколлинеарности: регрессоры не являются точной линейной комбинацией друг друга, в парном случае x не константа.
- Нулевое условное среднее ошибки: $E(\varepsilon \mid x) = 0$. Это ключевая предпосылка экзогенности.
- Гомоскедастичность: $Var(\varepsilon \mid x) = \sigma^2$, одинаковая для всех наблюдений.
- Отсутствие автокорреляции: $Cov(\varepsilon_i, \varepsilon_j \mid x) = 0$ при $i \neq j$.

Для точных выводов в малых выборках добавляют нормальность: $\varepsilon \mid x \sim N(0, \sigma^2)$.

3.2. Несмещённость

Запишем оценку наклона через ошибки. Поскольку $\Sigma(x_i - \bar{x}) = 0$, имеем

$$b_1 = \beta_1 + \Sigma (x_i - \bar{x})\varepsilon_i / \Sigma (x_i - \bar{x})^2.$$

Беря условное матожидание и используя $E(\varepsilon_i \mid x) = 0$, получаем $E(b_1 \mid x) = \beta_1$. Это несмещённость. Здесь видно, что для неё нужны только линейность, отсутствие вырожденности x и экзогенность. Гомоскедастичность и отсутствие автокорреляции для несмещённости не нужны.

3.3. Дисперсия оценок

При гомоскедастичности и отсутствии автокорреляции

$$Var(b_1 \mid x) = \sigma^2 / \Sigma (x_i - \bar{x})^2,$$
$$Var(b_0 \mid x) = \sigma^2 \cdot \Sigma x_i^2 / (n \cdot \Sigma (x_i - \bar{x})^2).$$

Из формулы видно, что точность оценки наклона растёт, когда меньше дисперсия ошибок, больше разброс регрессора и больше объём выборки. Отсюда практический совет при планировании эксперимента: стоит брать значения x пошире.

Неизвестную σ^2 оценивают через остатки:

$$s^2 = RSS / (n - 2).$$

Деление на $n - 2$, а не на n, делает оценку несмещённой: две степени свободы «потрачены» на оценивание двух параметров. Стандартная ошибка коэффициента — это корень из оценённой дисперсии: $se(b_1) = s / \sqrt{\Sigma(x_i - \bar{x})^2}$.

3.4. Теорема Гаусса–Маркова

При выполнении условий Гаусса–Маркова МНК-оценки являются наилучшими в классе линейных несмещённых оценок (BLUE — best linear unbiased estimator). «Наилучшие» означает «с наименьшей дисперсией». Линейные — значит линейные функции от y.

Идея доказательства для b_1. Любая линейная оценка имеет вид $\beta = \Sigma\, c_i y_i$. Условие несмещённости при любых β даёт $\Sigma c_i = 0$ и $\Sigma c_i x_i = 1$. Представим $c_i = w_i + d_i$, где $w_i = (x_i - \bar{x})/\Sigma(x_j - \bar{x})^2$ — веса МНК. Из ограничений следует $\Sigma w_i d_i = 0$, поэтому $\mathrm{Var}(\beta) = \sigma^2 \Sigma w_i^2 + \sigma^2 \Sigma d_i^2 \geq \mathrm{Var}(b_1)$, и равенство достигается только при $d_i = 0$.

Важно, что теорема ничего не говорит о нелинейных или смещённых оценках. Например, гребневая регрессия даёт смещённые оценки, которые могут иметь меньшую среднеквадратичную ошибку.

3.5. Состоятельность

Состоятельность означает, что оценка сходится по вероятности к истинному значению при $n \to \infty$. Для МНК достаточно более слабого условия, чем $E(\varepsilon \mid x) = 0$: достаточно некоррелированности регрессора и ошибки, $\mathrm{Cov}(x, \varepsilon) = 0$. Тогда

$$\operatorname{plim} b_1 = \beta_1 + \mathrm{Cov}(x, \varepsilon) / \mathrm{Var}(x) = \beta_1.$$

Если же $\mathrm{Cov}(x, \varepsilon) \neq 0$, то оценка несостоятельна, и увеличение выборки не помогает. Это главная причина, по которой эндогенность считается самой серьёзной проблемой регрессионного анализа.

4. Множественная регрессия в матричной форме

4.1. Запись модели

Пусть есть k регрессоров и константа. Тогда

$$y = X\beta + \varepsilon,$$

где y — вектор размера $n \times 1$, X — матрица $n \times (k+1)$, первый столбец которой состоит из единиц, β — вектор $(k+1) \times 1$, ε — вектор ошибок $n \times 1$.

4.2. МНК-оценка

Минимизируем $S(b) = (y - Xb)^{\mathsf{T}}(y - Xb) = y^{\mathsf{T}}y - 2b^{\mathsf{T}}X^{\mathsf{T}}y + b^{\mathsf{T}}X^{\mathsf{T}}Xb$. Градиент по b:

$$\partial S/\partial b = -2X^{\mathsf{T}}y + 2X^{\mathsf{T}}Xb = 0 \Rightarrow X^{\mathsf{T}}Xb = X^{\mathsf{T}}y.$$

Если матрица $X^{\mathsf{T}}X$ невырождена (столбцы X линейно независимы), то

$$b = (X^{\mathsf{T}}X)^{-1}X^{\mathsf{T}}y.$$

Матрица вторых производных $2X^{\mathsf{T}}X$ положительно определена, поэтому найденная точка действительно минимум.

Остатки $e = y - Xb$ удовлетворяют $X^{\mathsf{T}}e = 0$. Геометрически: вектор предсказаний $\hat{y} = Xb$ есть ортогональная проекция y на пространство столбцов X, а остатки ортогональны этому пространству. Проекционная матрица

$$P = X(X^{\mathsf{T}}X)^{-1}X^{\mathsf{T}},\ M = I - P,$$

симметрична и идемпотентна: $P^2 = P$, $M^2 = M$. Остатки выражаются как $e = My = M\varepsilon$. След матрицы M равен $n - k - 1$, отсюда несмещённая оценка дисперсии ошибок

$$s^2 = e^Te / (n - k - 1).$$

4.3. Ковариационная матрица оценок

Подставляя $y = X\beta + \varepsilon$, получаем $b = \beta + (X^TX)^{-1}X^T\varepsilon$. При $E(\varepsilon \mid X) = 0$ оценка несмещённая. При $Var(\varepsilon \mid X) = \sigma^2 I$

$$Var(b \mid X) = \sigma^2(X^TX)^{-1}.$$

Стандартная ошибка j-го коэффициента — корень из j-го диагонального элемента матрицы $s^2(X^TX)^{-1}$.

4.4. Интерпретация «при прочих равных»

Коэффициент β_j во множественной регрессии показывает изменение y при росте x_j на единицу при неизменных остальных регрессорах. Это формализуется теоремой Фриша–Во–Ловелла: оценка b_j совпадает с оценкой из парной регрессии остатков y (очищенных от прочих регрессоров) на остатки x_j (тоже очищенных от прочих регрессоров). То есть коэффициент использует только ту часть вариации x_j, которая не объясняется другими переменными.

Отсюда практическое следствие: если x_j почти полностью объясняется другими регрессорами, у него остаётся мало «собственной» вариации, и коэффициент оценивается неточно. Это и есть мультиколлинеарность.

4.5. Скорректированный R^2

При добавлении любого регрессора, даже бессмысленного, R^2 не убывает, потому что МНК может просто поставить при нём ноль. Поэтому для сравнения моделей с разным числом регрессоров используют скорректированный коэффициент:

$$R^2adj = 1 - (RSS / (n - k - 1)) / (TSS / (n - 1)) = 1 - (1 - R^2)(n - 1)/(n - k - 1).$$

Он может уменьшиться при добавлении переменной и может быть отрицательным. Альтернативы для сравнения моделей — информационные критерии:

$$AIC = n \cdot \ln(RSS/n) + 2(k+1),$$
$$BIC = n \cdot \ln(RSS/n) + (k+1) \cdot \ln n.$$

Меньшее значение лучше. BIC штрафует за сложность сильнее и при больших выборках чаще выбирает компактные модели. Эти формулы — вариант для линейной регрессии с нормальными ошибками с точностью до константы; в Gretl и statsmodels формулы записаны через логарифм правдоподобия, но выводы о сравнении моделей одинаковые.

5. Проверка гипотез

5.1. t-тест для отдельного коэффициента

При нормальных ошибках статистика

$$t = (b_j - \beta_j^0) / se(b_j)$$

имеет распределение Стьюдента с $n - k - 1$ степенями свободы при верной нулевой гипотезе H_0: $\beta_j = \beta_j^0$. Чаще всего проверяют значимость, то есть $\beta_j^0 = 0$.

Двусторонний тест: H_0 отвергается на уровне α, если $|t| > t_{1-\alpha/2}(n - k - 1)$. Для больших выборок критическое значение на 5%-м уровне примерно 1,96. Правило «t больше двух — значим» — грубое, но рабочее приближение.

p-значение — это вероятность получить статистику, не менее экстремальную, чем наблюдаемая, если H_0 верна. Это не вероятность того, что H_0 верна. Маленькое p-значение говорит, что данные плохо согласуются с H_0.

Без предположения о нормальности t-статистика асимптотически нормальна при выполнении остальных условий, поэтому в больших выборках тесты остаются корректными приближённо.

5.2. Доверительные интервалы

$$b_j \pm t_{1-\alpha/2}(n - k - 1) \cdot se(b_j).$$

Правильная интерпретация: если многократно повторять выборку и строить интервал по этому правилу, в доле $1 - \alpha$ случаев интервал накроет истинное значение. Для конкретного посчитанного интервала нельзя сказать «β лежит в нём с вероятностью 95%» в частотном смысле.

Связь с тестом: гипотеза $\beta_j = c$ отвергается на уровне α тогда и только тогда, когда c не попадает в доверительный интервал уровня $1 - \alpha$.

5.3. F-тест для группы ограничений

Пусть нужно проверить q линейных ограничений одновременно, например $\beta_2 = \beta_3 = 0$. Оцениваем модель без ограничений (RSS_{ur}) и с ограничениями (RSS_r). Статистика

$$F = ((RSS_r - RSS_{ur}) / q) / (RSS_{ur} / (n - k - 1))$$

имеет распределение Фишера $F(q, n - k - 1)$ при верной H_0. Если ограничения не меняют зависимую переменную, то можно записать через R^2:

$$F = ((R^2_{ur} - R^2_r) / q) / ((1 - R^2_{ur}) / (n - k - 1)).$$

Частный случай — тест значимости регрессии в целом: H_0: $\beta_1 = \ldots = \beta_k = 0$. Тогда $R^2_r = 0$ и

$$F = (R^2 / k) / ((1 - R^2) / (n - k - 1)).$$

Возможна ситуация, когда каждый коэффициент по отдельности незначим по t-тесту, а вместе они значимы по F-тесту. Это типичный признак мультиколлинеарности: переменные вместе объясняют y, но их вклады трудно разделить.

5.4. Общая линейная гипотеза

В матричной форме гипотеза записывается как $R\beta = r$, где R — матрица $q \times (k+1)$. Статистика Вальда

$$W = (Rb - r)^T [R \cdot s^2 (X^T X)^{-1} \cdot R^T]^{-1} (Rb - r),$$

и $F = W/q$. Так удобно проверять, например, равенство двух коэффициентов $\beta_1 = \beta_2$ ($R = [0, 1, -1, 0, \ldots]$, $r = 0$) или то, что сумма эластичностей в производственной функции равна единице.

5.5. Ошибки I и II рода, мощность

Ошибка первого рода — отвергнуть верную H_0, её вероятность равна α. Ошибка второго рода — не отвергнуть ложную H_0. Мощность теста — вероятность отвергнуть ложную H_0. Мощность растёт с объёмом выборки, с величиной истинного отклонения от H_0 и с уменьшением дисперсии ошибок. «Незначимый» коэффициент в маленькой выборке не доказывает отсутствие эффекта, он лишь говорит, что данных недостаточно для вывода.

5.6. Множественное тестирование

Если проверить 20 независимых гипотез на 5%-м уровне, то даже если все они верны, в среднем одна окажется «значимой». Простейшая поправка Бонферрони: использовать уровень α/m для каждой из m гипотез. Это консервативно, но надёжно. При переборе спецификаций в поисках значимого результата (p-hacking) p-значения теряют свой смысл.

6. Функциональные формы и спецификация

6.1. Логарифмические модели

Четыре основных варианта и интерпретация коэффициента β_1:

- $y = \beta_0 + \beta_1 x$: рост x на 1 единицу → изменение y на β_1 единиц.
- $\ln y = \beta_0 + \beta_1 x$: рост x на 1 единицу → изменение y примерно на $100 \cdot \beta_1$ процентов (полулогарифмическая модель). Точная формула: $100 \cdot (\exp(\beta_1) - 1)$ процентов; при $|\beta_1| < 0{,}1$ разница мала.
- $y = \beta_0 + \beta_1 \ln x$: рост x на 1% → изменение y примерно на $\beta_1/100$ единиц.
- $\ln y = \beta_0 + \beta_1 \ln x$: рост x на 1% → изменение y на β_1 процентов. β_1 — эластичность.

Пример: модель спроса $\ln Q = 5{,}2 - 1{,}3 \ln P + 0{,}8 \ln I$. Ценовая эластичность $-1{,}3$ (спрос эластичен), эластичность по доходу 0,8 (нормальное благо, но не предмет роскоши).

Логарифмирование также часто уменьшает гетероскедастичность и влияние выбросов, потому что сжимает большие значения. Ограничение: логарифм определён только для положительных значений. Трюк $\ln(y + 1)$ для данных с нулями искажает интерпретацию, и его лучше применять осознанно.

6.2. Полиномиальные члены и взаимодействия

Модель $y = \beta_0 + \beta_1 x + \beta_2 x^2 + \varepsilon$ позволяет учесть нелинейный эффект. Предельный эффект теперь зависит от x:

$$\partial y / \partial x = \beta_1 + 2\beta_2 x.$$

При $\beta_1 > 0$ и $\beta_2 < 0$ зависимость имеет форму перевёрнутой параболы с вершиной в $x^* = -\beta_1/(2\beta_2)$. Классический пример — зависимость зарплаты от возраста или стажа.

Взаимодействие: $y = \beta_0 + \beta_1 x + \beta_2 z + \beta_3 xz + \varepsilon$. Эффект x зависит от z: $\partial y/\partial x = \beta_1 + \beta_3 z$. Отдельно коэффициент β_1 теперь показывает эффект x только при $z = 0$, что часто не имеет смысла; поэтому переменные полезно центрировать перед построением взаимодействий.

6.3. Фиктивные переменные

Фиктивная (дамми) переменная принимает значения 0 и 1. Модель

$$\text{зарплата} = \beta_0 + \beta_1 \cdot \text{стаж} + \beta_2 \cdot \text{жен} + \varepsilon$$

предполагает параллельные линии с разными константами для мужчин и женщин; β_2 — средняя разница при одинаковом стаже.

Если у признака m категорий, вводят $m - 1$ дамми. Если ввести все m при наличии константы, столбцы X станут линейно зависимыми (сумма дамми равна столбцу единиц) — это «ловушка фиктивных переменных». Опущенная категория становится базовой, и все коэффициенты дамми интерпретируются как отличие от неё.

Дамми на наклон: добавление произведения жен·стаж позволяет различаться и наклонам.

Если зависимая переменная в логарифмах, коэффициент при дамми интерпретируется как процентная разница: $100 \cdot (\exp(\beta) - 1)\%$.

6.4. Тест Чоу

Тест Чоу проверяет, одинаковы ли коэффициенты регрессии в двух подвыборках (например, до и после кризиса). Оцениваем модель на всей выборке (RSS_p), затем отдельно на первой (RSS_1) и второй (RSS_2) частях. Статистика

$$F = ((RSS_p - RSS_1 - RSS_2) / (k + 1)) / ((RSS_1 + RSS_2) / (n - 2(k + 1)))$$

имеет распределение $F(k + 1, n - 2(k + 1))$ при H_0 о равенстве всех коэффициентов. Эквивалентный способ — ввести дамми для подвыборки и её взаимодействия со всеми регрессорами и проверить их совместную незначимость F-тестом. Тест Чоу предполагает одинаковую дисперсию ошибок в подвыборках.

6.5. Пропущенные и лишние переменные

Пусть истинная модель $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \varepsilon$, а оценивается у на x_1 без x_2. Тогда

$$E(\tilde{b}_1) = \beta_1 + \beta_2 \cdot \delta_1,$$

где δ_1 — коэффициент регрессии x_2 на x_1. Смещение отсутствует только если $\beta_2 = 0$ или x_1 и x_2 некоррелированы. Знак смещения определяется знаками β_2 и корреляции x_1 и x_2.

Пример: в регрессии зарплаты на образование пропущены способности. Способности положительно влияют на зарплату ($\beta_2 > 0$) и положительно коррелированы с образованием ($\delta_1 > 0$), поэтому оценка отдачи от образования завышена.

Лишняя переменная ($\beta_2 = 0$ на самом деле) не вызывает смещения, но увеличивает дисперсию оценок, особенно если лишняя переменная коррелирована с нужными. Итог: пропустить важное хуже, чем добавить лишнее, но бездумно добавлять всё подряд тоже не стоит.

6.6. Тест Рамсея RESET

Тест проверяет, не пропущены ли нелинейные функции регрессоров. После оценивания основной модели в неё добавляют $\hat{y}^2$ и $\hat{y}^3$ и проверяют их совместную значимость F-тестом. Если они значимы, функциональная форма, скорее всего, неверна. Тест не говорит, что именно не так, только сигнализирует о проблеме.

6.7. Выбросы и влиятельные наблюдения

Отдельные наблюдения могут сильно влиять на оценки МНК, потому что квадрат штрафует большие отклонения. Полезные диагностики:

- Рычаг (leverage) h_i — диагональный элемент матрицы P. Средний рычаг равен (k+1)/n; наблюдения с h_i больше 2–3 средних заслуживают внимания.
- Стьюдентизированные остатки: остаток, делённый на свою оценённую стандартную ошибку.
- Расстояние Кука: насколько изменятся все предсказания, если удалить i-е наблюдение. Ориентир — значения больше 4/n или больше 1.

Удалять наблюдения только потому, что они «портят» результат, нельзя. Сначала нужно проверить, не ошибка ли это данных, и потом сравнить результаты с этим наблюдением и без него, указав это явно.

7. Мультиколлинеарность

7.1. Что это и почему это проблема

Строгая мультиколлинеарность — точная линейная зависимость между регрессорами. Тогда X^TX вырождена, и МНК-оценки не существуют единственным образом. Программы в такой ситуации либо выдают ошибку, либо автоматически выкидывают одну из переменных.

На практике чаще встречается нестрогая мультиколлинеарность: регрессоры сильно, но не идеально коррелированы. Оценки существуют, остаются несмещёнными и BLUE, но их дисперсии большие. Формула дисперсии коэффициента во множественной регрессии:

$$\mathrm{Var}(b_j) = \sigma^2 / (\Sigma(x_{ij} - \bar{x}_j)^2 \cdot (1 - R^2_j)),$$

где R^2_j — коэффициент детерминации из регрессии x_j на остальные регрессоры. Когда R^2_j близок к единице, знаменатель стремится к нулю, и дисперсия раздувается.

7.2. Признаки

- Высокий R^2 и значимый F-тест при незначимых t-статистиках отдельных коэффициентов.
- Оценки сильно меняются при добавлении или удалении одной переменной или нескольких наблюдений.
- Знаки коэффициентов противоречат теории.
- Высокие парные корреляции между регрессорами (но их отсутствие не гарантирует отсутствия мультиколлинеарности: зависимость может быть между тремя переменными сразу).

7.3. VIF и число обусловленности

Коэффициент вздутия дисперсии:

$$\mathrm{VIF}_j = 1 / (1 - R^2_j).$$

VIF = 1 означает отсутствие связи с другими регрессорами. Часто используемое правило: VIF > 10 сигнализирует о серьёзной мультиколлинеарности, иногда берут порог 5. Это условные ориентиры, а не тесты.

Другая мера — число обусловленности матрицы X^TX (после масштабирования столбцов): корень из отношения наибольшего собственного числа к наименьшему. Значения больше 30 считаются тревожными (диагностика Белсли–Кух–Уэлша).

7.4. Что делать

- Ничего, если цель — прогноз, а мультиколлинеарность устойчива в данных. Прогнозы от неё почти не страдают.
- Ничего, если коллинеарны контрольные переменные, а интересующий коэффициент оценивается точно. VIF важен только для тех коэффициентов, которые интерпретируются.
- Увеличить выборку или найти данные с большей независимой вариацией регрессоров.
- Объединить коллинеарные переменные в индекс или использовать главные компоненты (теряется прямая интерпретация).
- Использовать априорную информацию: например, наложить ограничение на сумму коэффициентов.
- Регуляризация (гребневая регрессия, лассо) — смещает оценки, но уменьшает их дисперсию. В ML это стандарт, в классической эконометрике применяется реже из-за смещения.
- Удалить переменную можно только если есть содержательные основания; иначе возникает смещение из-за пропущенной переменной, которое хуже большой дисперсии.

Отдельный частый случай — коллинеарность x и x^2 в полиномиальных моделях. Центрирование x перед возведением в квадрат резко её снижает, не меняя содержательно модель.

8. Гетероскедастичность

8.1. Определение и последствия

Гетероскедастичность — непостоянство дисперсии ошибок: $\mathrm{Var}(\varepsilon_i \mid X) = \sigma_i^2$. Типичные примеры: расходы богатых семей варьируются сильнее, чем бедных; ошибки в данных по крупным фирмам больше в абсолютном выражении.

Последствия:

- МНК-оценки остаются несмещёнными и состоятельными.
- Оценки перестают быть эффективными (не BLUE).
- Обычная формула стандартных ошибок $\sigma^2(X^TX)^{-1}$ неверна, поэтому t- и F-тесты и доверительные интервалы некорректны. Это главная практическая проблема.

8.2. Графическая диагностика

Строят график квадратов остатков (или модулей) против предсказанных значений или против подозрительного регрессора. Форма «раструба», когда разброс растёт вместе с x, — классический признак.

8.3. Тест Голдфелда–Квандта

Предполагается, что дисперсия монотонно зависит от некоторой переменной z. Наблюдения упорядочивают по z, выбрасывают среднюю часть (обычно около четверти), оценивают регрессию отдельно по первым и последним n' наблюдениям. Статистика

$$GQ = RSS_2 / RSS_1 \sim F(n' - k - 1, n' - k - 1)$$

при гомоскедастичности. Тест требует знать переменную, с которой связана дисперсия, и нормальности ошибок.

8.4. Тест Бройша–Пагана

Вспомогательная регрессия квадратов остатков на регрессоры (или на набор переменных z):

$$e_i^2 = \alpha_0 + \alpha_1 z_{1i} + \ldots + \alpha_p z_{pi} + u_i.$$

Статистика $LM = n \cdot R^2_{aux}$ асимптотически распределена как $\chi^2(p)$ при H_0: $\alpha_1 = \ldots = \alpha_p = 0$ (гомоскедастичность). Вариант Коэнкера с этой формулой устойчив к ненормальности ошибок; в некоторых программах по умолчанию считается исходный вариант через ESS/2 с нормировкой, его стоит отличать.

8.5. Тест Уайта

Во вспомогательную регрессию e_i^2 включают все регрессоры, их квадраты и попарные произведения. Статистика $n \cdot R^2 \sim \chi^2(p)$, где p — число регрессоров вспомогательной регрессии без константы. Тест общий, не требует предположения о форме гетероскедастичности, но при многих регрессорах число степеней свободы быстро растёт и мощность падает. Упрощённый вариант: регрессия e_i^2 на $\hat{y}_i$ и $\hat{y}_i^2$.

Значимый тест Уайта может также сигнализировать о неправильной функциональной форме, а не только о гетероскедастичности.

8.6. Робастные стандартные ошибки

Самое распространённое решение — оставить МНК-оценки и исправить стандартные ошибки. Оценка ковариационной матрицы Уайта (HC0):

$$\widehat{Var}(b) = (X^TX)^{-1} (\Sigma\, e_i^2\, x_i x_i^T)\, (X^TX)^{-1}.$$

Форма «сэндвича»: «хлеб» $(X^TX)^{-1}$, «начинка» $\Sigma e_i^2 x_i x_i^T$. Модификации HC1 (умножение на $n/(n-k-1)$), HC2, HC3 лучше ведут себя в малых выборках; HC3 часто рекомендуют при $n < 250$. В Gretl опция «робастные стандартные ошибки» в окне МНК; в statsmodels — fit(cov_type="HC3").

Робастные ошибки корректны асимптотически и при гомоскедастичности тоже, поэтому в пространственных данных их часто используют по умолчанию.

8.7. Взвешенный МНК

Если известна форма дисперсии $\sigma_i^2 = \sigma^2 \cdot h_i$, то делим всё уравнение на $\sqrt{h_i}$:

$$y_i/\sqrt{h_i} = \beta_0/\sqrt{h_i} + \beta_1 x_i/\sqrt{h_i} + \varepsilon_i/\sqrt{h_i}.$$

Новые ошибки гомоскедастичны, и МНК для преобразованной модели даёт BLUE-оценки. Это взвешенный МНК (WLS) с весами $1/h_i$. Пример: если дисперсия пропорциональна x, делим на $\sqrt{x}$; если пропорциональна x^2, делим на x.

Если форма неизвестна, применяют доступный обобщённый МНК (FGLS): оценивают регрессию $\ln(e_i^2)$ на регрессоры, получают $\hat{h}_i = \exp(\text{предсказание})$ и используют веса $1/\hat{h}_i$. FGLS эффективнее МНК асимптотически, но в малых выборках неверная модель дисперсии может навредить. Компромисс: FGLS плюс робастные ошибки.

8.8. Обобщённый МНК в общем виде

Если $\mathrm{Var}(\varepsilon \mid X) = \sigma^2\Omega$ с известной положительно определённой Ω, то обобщённый МНК (GLS):

$$b_{GLS} = (X^T\Omega^{-1}X)^{-1}X^T\Omega^{-1}y,\ \mathrm{Var}(b_{GLS}) = \sigma^2(X^T\Omega^{-1}X)^{-1}.$$

Это частный случай теоремы Айткена: GLS — BLUE при такой структуре ошибок. Взвешенный МНК — GLS с диагональной Ω; поправки на автокорреляцию — GLS с ленточной структурой Ω.

9. Автокорреляция

9.1. Определение

Автокорреляция (сериальная корреляция) — корреляция ошибок разных наблюдений, $\mathrm{Cov}(\varepsilon_t, \varepsilon_s) \neq 0$. Типична для временных рядов: шоки длятся несколько периодов, экономика инерционна. В пространственных данных бывает пространственная автокорреляция (соседние регионы похожи) и корреляция внутри кластеров (ученики одного класса).

Простейшая модель — авторегрессия первого порядка:

$$\varepsilon_t = \rho\varepsilon_{t-1} + u_t,\ |\rho| < 1,$$

где u_t — белый шум. Тогда $\mathrm{Corr}(\varepsilon_t, \varepsilon_{t-s}) = \rho^s$, $\mathrm{Var}(\varepsilon_t) = \sigma_u^2/(1-\rho^2)$.

9.2. Последствия

Аналогичны гетероскедастичности: оценки МНК несмещённые (при строгой экзогенности), но неэффективные, а стандартные ошибки неверны. При положительной автокорреляции и положительно коррелированном регрессоре обычные стандартные ошибки занижены, и коэффициенты кажутся значимее, чем они есть.

Особый случай: если в модели есть лаг зависимой переменной y_{t-1} и ошибки автокоррелированы, то y_{t-1} коррелирует с ε_t, и МНК становится несостоятельным. Это уже проблема эндогенности.

Автокорреляция в остатках часто сигнализирует о неправильной спецификации: пропущенном лаге, тренде, сезонности или неверной функциональной форме.

9.3. Тест Дарбина–Уотсона

$$DW = \Sigma_{t=2}^{n}(e_t - e_{t-1})^2 \,/\, \Sigma_{t=1}^{n} e_t^2 \approx 2(1-\hat{\rho}).$$

$DW \approx 2$ — нет автокорреляции первого порядка, DW близко к 0 — сильная положительная, близко к 4 — сильная отрицательная. Критические значения зависят от матрицы X, поэтому таблицы дают границы dL и dU:

- $DW < dL$ — отвергаем H_0, есть положительная автокорреляция;
- $DW > dU$ — не отвергаем H_0;
- $dL \le DW \le dU$ — зона неопределённости.

Ограничения: тест только для AR(1), требует константы в модели и строгой экзогенности; неприменим при наличии лага зависимой переменной (для этого случая есть h-статистика Дарбина).

9.4. Тест Бройша–Годфри

Более общий тест. Вспомогательная регрессия:

$$e_t = \alpha_0 + \alpha_1 x_{1t} + \ldots + \alpha_k x_{kt} + \gamma_1 e_{t-1} + \ldots + \gamma_p e_{t-p} + v_t.$$

Статистика $(n - p) \cdot R^2 \sim \chi^2(p)$ при H_0: $\gamma_1 = \ldots = \gamma_p = 0$. Работает с лагированной зависимой переменной, позволяет проверять автокорреляцию высоких порядков (например, p = 4 для квартальных данных или 12 для месячных).

9.5. Исправление

Процедура Кохрейна–Оркатта. Если ρ известно, делаем квазиразности:

$$y_t - \rho y_{t-1} = \beta_0(1 - \rho) + \beta_1(x_t - \rho x_{t-1}) + u_t.$$

Ошибки u_t некоррелированы, МНК даёт эффективные оценки. Поскольку ρ неизвестно, итерационно: МНК → остатки → оценка ρ регрессией e_t на e_{t-1} → преобразование → МНК → новые остатки → … до сходимости. Первое наблюдение при этом теряется.

Процедура Прайса–Уинстена отличается тем, что сохраняет первое наблюдение, умножая его на $\sqrt{(1 - \rho^2)}$. В малых выборках это заметно улучшает оценки.

Стандартные ошибки Ньюи–Уэста (HAC) — аналог робастных ошибок Уайта, устойчивые и к гетероскедастичности, и к автокорреляции. Используют весовые коэффициенты Бартлетта $w_l = 1 - l/(L + 1)$ для лагов l до L. Выбор L: часто берут целую часть 4·(n/100)^(2/9) или около n^(1/4). Преимущество — не нужно моделировать структуру автокорреляции, МНК-оценки сохраняются.

Если же автокорреляция вызвана пропущенной динамикой, правильнее изменить модель: добавить лаги y и x (модель ADL), тренд или сезонные дамми.

10. Эндогенность и инструментальные переменные

10.1. Источники эндогенности

Регрессор эндогенный, если коррелирован с ошибкой: $\mathrm{Cov}(x, \varepsilon) \neq 0$. Тогда МНК смещён и несостоятелен. Основные причины:

- Пропущенная переменная, коррелированная с регрессором.
- Ошибки измерения в регрессоре. Если x* наблюдается как x = x* + v с независимым шумом v, то в парной регрессии $\mathrm{plim}\, b_1 = \beta_1 \cdot \mathrm{Var}(x^*)/(\mathrm{Var}(x^*) + \mathrm{Var}(v))$. Коэффициент смещается к нулю — затухание (attenuation bias).
- Одновременность (обратная связь): y влияет на x так же, как x на y. Классический пример — спрос и предложение: цена и количество определяются одновременно.
- Самоотбор в выборку: например, зарплаты наблюдаются только у работающих.

10.2. Инструментальная переменная

Инструмент z для эндогенного x должен удовлетворять двум условиям:

- Релевантность: $\mathrm{Cov}(z, x) \neq 0$. Проверяется по данным.
- Экзогенность (исключающее ограничение): $\mathrm{Cov}(z, \varepsilon) = 0$, то есть z влияет на y только через x. В точно идентифицированной модели не проверяется статистически, обосновывается содержательно.

В парном случае IV-оценка:

$$b_{IV} = \mathrm{Cov}(z, y) / \mathrm{Cov}(z, x), \quad \mathrm{plim}\, b_{IV} = \beta_1 + \mathrm{Cov}(z, \varepsilon)/\mathrm{Cov}(z, x) = \beta_1.$$

Классические примеры инструментов из литературы: расстояние до ближайшего колледжа как инструмент для образования; квартал рождения для числа лет обучения (через законы об обязательном образовании); погодные условия для предложения сельхозпродукции в модели спроса.

10.3. Двухшаговый МНК

При нескольких инструментах используют 2МНК (2SLS).

Шаг 1. Регрессия эндогенного x на все инструменты и все экзогенные регрессоры, получение $\hat{x}$.

Шаг 2. Регрессия y на $\hat{x}$ и экзогенные регрессоры.

В матричном виде, где Z — матрица всех инструментов и экзогенных переменных, $P_Z = Z(Z^TZ)^{-1}Z^T$:

$$b_{2SLS} = (X^TP_ZX)^{-1}X^TP_Zy.$$

Предостережение: если делать два шага вручную двумя командами МНК, коэффициенты будут правильными, а стандартные ошибки на втором шаге — нет, потому что остатки считаются с $\hat{x}$ вместо x. Нужно использовать готовую процедуру (в Gretl — «Модель → Инструментальные переменные → 2МНК», в Python — linearmodels.IV2SLS).

Условие порядка: число инструментов (исключённых экзогенных переменных) должно быть не меньше числа эндогенных регрессоров. Если равно — точная идентификация, если больше — сверхидентификация.

10.4. Слабые инструменты

Если инструмент слабо связан с x, IV-оценка сильно смещена в сторону МНК, а её распределение далеко от нормального даже в больших выборках. Кроме того, даже небольшая корреляция инструмента с ошибкой при слабом инструменте даёт большую несостоятельность, потому что Cov(z, ε) делится на маленькую Cov(z, x).

Диагностика: F-статистика совместной значимости исключённых инструментов на первом шаге. Эмпирическое правило Стока–Стайгера — $F > 10$. Более современные рекомендации требуют заметно больших значений для надёжных выводов.

10.5. Тесты

Тест Хаусмана (Ву–Хаусмана) на эндогенность: сравнивает МНК и IV-оценки. При экзогенности обе состоятельны, но МНК эффективнее; при эндогенности состоятельна только IV. Регрессионный вариант: добавить остатки первого шага $\hat{v}$ в исходное уравнение и проверить их значимость t-тестом. Значимость означает эндогенность.

Тест Саргана (Хансена) на сверхидентифицирующие ограничения: регрессия остатков 2МНК на все инструменты, $n \cdot R^2 \sim \chi^2(m - p)$, где m — число инструментов, p — число эндогенных регрессоров. Отвержение говорит, что хотя бы один инструмент, вероятно, невалиден. Тест проверяет совместимость инструментов друг с другом, но не их валидность в абсолютном смысле.

11. Модели бинарного выбора

11.1. Линейная модель вероятности

Если $y \in \{0, 1\}$, то $E(y \mid x) = P(y = 1 \mid x)$. Линейная модель вероятности (LPM): $P(y = 1 \mid x) = x^T\beta$, оценивается обычным МНК. Плюсы: простота, коэффициенты — это прямые предельные эффекты на вероятность. Минусы:

- Прогнозы могут выходить за $[0, 1]$.
- Ошибки гетероскедастичны по построению: $\mathrm{Var}(\varepsilon \mid x) = p(1 - p)$, где $p = x^T\beta$. Обязательны робастные стандартные ошибки.
- Постоянный предельный эффект неправдоподобен у краёв.

11.2. Логит и пробит

Используется функция распределения F, отображающая $\mathbb{R}$ в $(0, 1)$:

$$P(y = 1 \mid x) = F(x^T\beta).$$

Логит: $F(t) = \Lambda(t) = 1/(1 + e^{-t})$. Пробит: $F(t) = \Phi(t)$, функция распределения стандартного нормального закона.

Интерпретация через латентную переменную: $y^* = x^T\beta + \varepsilon$, $y = 1$ если $y^* > 0$. При логистической ε получается логит, при нормальной — пробит. Масштаб β не идентифицирован, поэтому дисперсию ε фиксируют ($\pi^2/3$ для логита, 1 для пробита). Отсюда известное приблизительное соотношение: логит-коэффициенты примерно в 1,6–1,8 раза больше пробит-коэффициентов.

11.3. Оценивание методом максимального правдоподобия

Логарифм функции правдоподобия:

$$\ln L(\beta) = \Sigma\,[y_i \ln F(x_i^T\beta) + (1 - y_i) \ln(1 - F(x_i^T\beta))].$$

Максимизируется численно (метод Ньютона–Рафсона или BHHH). Для логита $\ln L$ вогнута, поэтому максимум единственный. Условие первого порядка для логита особенно простое: $\Sigma\,(y_i - \Lambda(x_i^T\beta))x_i = 0$. Связь с ML очевидна: это та же функция потерь, что и бинарная кросс-энтропия, а логистическая регрессия в sklearn — логит с регуляризацией по умолчанию.

ММП-оценки состоятельны, асимптотически нормальны и асимптотически эффективны при правильной спецификации. Гипотезы проверяют z-тестами (аналог t) и тестом отношения правдоподобия:

$$LR = 2(\ln L_{ur} - \ln L_r) \sim \chi^2(q).$$

11.4. Предельные эффекты

Коэффициенты логита и пробита не равны предельным эффектам. Для непрерывного x_j:

$$\partial P/\partial x_j = f(x^T\beta)\cdot\beta_j,$$

где f — плотность. Эффект зависит от точки. Варианты отчёта:

- Предельный эффект в среднем (MEM): подставить средние значения x.
- Средний предельный эффект (AME): посчитать для каждого наблюдения и усреднить. Обычно предпочтительнее.

Знак предельного эффекта совпадает со знаком β_j. Для логита удобна интерпретация через шансы: $\exp(\beta_j)$ — во сколько раз меняется отношение шансов

$p/(1-p)$ при росте x_j на единицу.

Для дамми-переменной правильнее считать дискретное изменение: $P(y=1 \mid d=1, x) - P(y=1 \mid d=0, x)$.

11.5. Качество подгонки

Обычный R^2 не применяется. Используют:

- Псевдо-R^2 Макфаддена: $1 - \ln L / \ln L_0$, где L_0 — правдоподобие модели только с константой. Значения 0,2–0,4 считаются хорошими.
- Долю правильных предсказаний при пороге 0,5. При несбалансированных классах вводит в заблуждение: если 95% нулей, тривиальное правило «всегда 0» даёт 95%.
- Матрицу ошибок, ROC-кривую и AUC — как в машинном обучении.

12. Временные ряды: основы

12.1. Стационарность

Ряд y_t слабо стационарен, если его среднее и дисперсия постоянны, а ковариация $\mathrm{Cov}(y_t, y_{t-s})$ зависит только от лага s. Большинство классических результатов для регрессии временных рядов требует стационарности (или хотя бы слабой зависимости).

Примеры нестационарности: детерминированный тренд $y_t = \alpha + \delta t + \varepsilon_t$ и случайное блуждание $y_t = y_{t-1} + \varepsilon_t$. У случайного блуждания дисперсия растёт линейно со временем: $\mathrm{Var}(y_t) = t\sigma^2$, а шоки не затухают никогда.

12.2. Ложная регрессия

Если регрессировать одно случайное блуждание на другое, независимое от него, t-статистика наклона часто выходит «значимой», R^2 высокий, а DW очень мал. Это ложная регрессия (Грейнджер–Ньюболд). Эвристика: если $R^2 > DW$, стоит подозревать ложную регрессию.

12.3. Модели ARMA

Авторегрессия AR(p):

$$y_t = c + \varphi_1 y_{t-1} + \ldots + \varphi_p y_{t-p} + \varepsilon_t.$$

AR(1) стационарна при $|\varphi_1| < 1$, её среднее $c/(1-\varphi_1)$, автокорреляционная функция затухает геометрически: $\rho_s = \varphi_1^s$.

Скользящее среднее MA(q):

$$y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \ldots + \theta_q \varepsilon_{t-}_q.$$

Всегда стационарна; автокорреляции обрываются после лага q.

Идентификация порядка по графикам: у AR(p) частная автокорреляционная функция (PACF) обрывается после лага p, а ACF затухает; у MA(q) — наоборот. На практике порядок выбирают перебором с AIC/BIC и проверкой остатков на белый шум тестом Льюнга–Бокса:

$$Q = n(n+2) \sum_{s=1}^{m} \hat{\rho}_s^2 / (n-s) \sim \chi^2(m-p-q).$$

12.4. Единичный корень и тест Дики–Фуллера

Проверяется H_0: ряд имеет единичный корень (нестационарен). Регрессия

$$\Delta y_t = \alpha + \delta t + \gamma y_{t-1} + \Sigma\, \lambda_i \Delta y_{t-i} + \varepsilon_t,$$

H_0: $\gamma = 0$ против H_1: $\gamma < 0$. Лаги разностей (расширенный тест ADF) убирают автокорреляцию остатков. Ключевой момент: t-статистика при γ при H_0 не имеет распределения Стьюдента, используются специальные критические значения Дики–Фуллера (на 5%-м уровне примерно −2,86 с константой и −3,41 с константой и трендом для больших выборок).

Комплементарный тест KPSS проверяет обратную нулевую гипотезу — стационарность. Если ADF не отвергает единичный корень, а KPSS отвергает стационарность, вывод о нестационарности становится убедительнее.

Ряд, становящийся стационарным после d разностей, называют интегрированным порядка d, I(d). ARIMA(p, d, q) — это ARMA(p, q) для d-й разности ряда.

12.5. Коинтеграция

Если y_t и x_t — I(1), но существует β, при котором $y_t - \beta x_t$ стационарна, ряды коинтегрированы: у них есть долгосрочное равновесное соотношение. Процедура Энгла–Грейнджера: оценить МНК y_t на x_t, проверить остатки на единичный корень (со специальными критическими значениями). При коинтеграции строится модель коррекции ошибок:

$$\Delta y_t = \alpha + \gamma \Delta x_t + \lambda(y_{t-1} - \beta x_{t-1}) + \varepsilon_t,\ \lambda < 0.$$

Коэффициент λ показывает скорость возврата к равновесию: какая доля отклонения устраняется за один период.

13. Панельные данные

13.1. Модель с ненаблюдаемым эффектом

$$y_{it} = x_{it}^{\top}\beta + \alpha_i + \varepsilon_{it},\ i = 1, \ldots, N,\ t = 1, \ldots, T.$$

α_i — индивидуальный эффект, постоянный во времени (например, способности работника, культура фирмы, география региона). Вопрос в том, коррелирует ли α_i с регрессорами.

13.2. Объединённая регрессия (pooled OLS)

Игнорирует панельную структуру, α_i уходит в ошибку. Состоятельна, только если α_i не коррелирует с x_{it}. Даже в этом случае ошибки одного объекта коррелированы во времени, поэтому нужны стандартные ошибки, кластеризованные по объектам.

13.3. Фиксированные эффекты

Внутригрупповое преобразование: вычитаем из каждого наблюдения среднее по объекту:

$$y_{it} - \bar{y}_i = (x_{it} - \bar{x}_i)^{\top}\beta + (\varepsilon_{it} - \bar{\varepsilon}_i).$$

α_i исчезает, поэтому оценка состоятельна при любой корреляции α_i с регрессорами. Эквивалентно включению N дамми для объектов (LSDV). Цена: нельзя оценить эффекты переменных, постоянных во времени (пол, регион рождения), и

используется только внутриобъектная вариация, что снижает точность. Число степеней свободы: $NT - N - k$.

Альтернатива — первые разности: $\Delta y_{it} = \Delta x_{it}^{\top}\beta + \Delta\varepsilon_{it}$. При $T = 2$ совпадает с FE; при $T > 2$ эффективнее та, у которой ошибки ближе к некоррелированным.

13.4. Случайные эффекты

Предполагается, что α_i не коррелирует с регрессорами, и α_i рассматривается как часть составной ошибки $v_{it} = \alpha_i + \varepsilon_{it}$. Ошибки одного объекта коррелированы, поэтому применяется GLS с квазиусреднением:

$$y_{it} - \theta\bar{y}_i = (x_{it} - \theta\bar{x}_i)^{\top}\beta + \ldots, \quad \theta = 1 - \sqrt{(\sigma^2_\varepsilon / (\sigma^2_\varepsilon + T\sigma^2_\alpha))}.$$

При $\theta = 0$ получаем pooled OLS, при $\theta \to 1$ — фиксированные эффекты. RE эффективнее FE и позволяет оценивать эффекты постоянных во времени переменных, но несостоятельна, если α_i коррелирует с регрессорами.

13.5. Выбор модели

- Тест Хаусмана: H_0 — α_i не коррелирует с регрессорами (обе оценки состоятельны, RE эффективнее). Статистика $H = (b_{FE} - b_{RE})^{\top}[\mathrm{Var}(b_{FE}) - \mathrm{Var}(b_{RE})]^{-1}(b_{FE} - b_{RE}) \sim \chi^2(k)$. Отвержение → FE.
- Тест Бройша–Пагана для панелей: H_0: $\sigma^2_\alpha = 0$ (pooled против RE).
- F-тест на совместную значимость индивидуальных эффектов (pooled против FE).

В прикладных работах с данными по странам и регионам чаще выбирают FE, потому что предположение RE о некоррелированности редко правдоподобно.

13.6. Временные эффекты и двусторонняя модель

Добавление дамми по периодам λ_t учитывает общие для всех объектов шоки (кризисы, инфляцию). Модель с α_i и λ_t называется двусторонней моделью фиксированных эффектов. На ней основан метод «разность разностей» (difference-in-differences), где эффект политики оценивается как коэффициент при взаимодействии «объект подвергся воздействию» × «период после воздействия». Ключевое предположение — параллельные тренды в отсутствие воздействия.

14. Практическая памятка

14.1. Порядок работы с моделью

- Посмотреть на данные: описательные статистики, гистограммы, диаграммы рассеяния, пропуски, выбросы.
- Сформулировать спецификацию из теории, а не из перебора.
- Оценить МНК, проверить знаки и порядки величин коэффициентов.
- Проверить: RESET, мультиколлинеарность (VIF), гетероскедастичность (Бройш–Паган, Уайт), автокорреляцию для временных рядов (DW, Бройш–Годфри), нормальность остатков (Харке–Бера), влиятельные наблюдения.
- Исправить: изменить форму, добавить переменные, использовать робастные или HAC-ошибки, WLS/FGLS, IV.
- Проверить устойчивость результатов к альтернативным спецификациям.
- Интерпретировать коэффициенты с указанием единиц измерения и осторожно в части причинности.

14.2. Тест Харке–Бера

$$JB = n/6 \cdot (S^2 + (K - 3)^2/4) \sim \chi^2(2),$$

где S — коэффициент асимметрии, K — эксцесс остатков. H_0 — нормальность. В больших выборках нормальность не обязательна для выводов благодаря асимптотике, поэтому отвержение JB при n в несколько тысяч само по себе не страшно.

14.3. Соответствие инструментов

- Gretl: «Модель → МНК»; в окне модели меню «Тесты»: пропущенные переменные, нелинейность (квадраты, логарифмы), RESET, гетероскедастичность (Уайт, Бройш–Паган), нормальность остатков, автокорреляция (LM), коллинеарность (VIF), тест Чоу.
- Python, statsmodels: smf.ols("y ~ x1 + x2", data=df).fit(); робастные ошибки — fit(cov_type="HC3"); HAC — fit(cov_type="HAC", cov_kwds={"maxlags": 4}); тесты — модуль statsmodels.stats.diagnostic (het_breuschpagan, het_white, acorr_breusch_godfrey, linear_reset); VIF — variance_inflation_factor; ADF — statsmodels.tsa.stattools.adfuller; логит — smf.logit(...).fit() и get_margeff() для предельных эффектов.
- Python, linearmodels: PanelOLS (FE, entity_effects=True), RandomEffects, IV2SLS.

14.4. Частые ошибки на экзамене и в работах

- Путать ошибку и остаток.
- Считать, что гетероскедастичность делает оценки смещёнными.
- Интерпретировать коэффициенты логита как предельные эффекты.
- Делать 2МНК вручную и брать стандартные ошибки второго шага.
- Применять DW при наличии лага зависимой переменной.
- Сравнивать R^2 моделей с разными зависимыми переменными (y и ln y).
- Считать незначимый коэффициент доказательством отсутствия эффекта.
- Удалять переменную из-за высокого VIF, не думая о смещении.

15. Дополнения: ММП, цензурированные данные, прогноз

15.1. Линейная регрессия как задача максимального правдоподобия

Если $\varepsilon \sim N(0, \sigma^2 I)$, то плотность одного наблюдения

$$f(y_i \mid x_i) = (2\pi\sigma^2)^{\wedge}(-1/2) \cdot \exp(-(y_i - x_i^T\beta)^2 / (2\sigma^2)),$$

а логарифм правдоподобия выборки

$$\ln L(\beta, \sigma^2) = -(n/2) \ln(2\pi) - (n/2) \ln \sigma^2 - (1/(2\sigma^2)) \Sigma (y_i - x_i^T\beta)^2.$$

При фиксированном σ^2 максимизация по β эквивалентна минимизации суммы квадратов, поэтому ММП-оценка β совпадает с МНК-оценкой. Оценка дисперсии по ММП равна RSS/n, то есть она смещена вниз (делится на n, а не на $n - k - 1$); в больших выборках разница исчезает.

Подставляя оценки, получаем максимальное значение

$$\ln \hat{L} = -(n/2)(1 + \ln(2\pi) + \ln(RSS/n)).$$

Именно через него программы считают AIC = −2 ln ℒ̂ + 2p и BIC = −2 ln ℒ̂ + p ln n, где p — число оцениваемых параметров.

15.2. Три классических теста

Для проверки ограничений в моделях, оцениваемых ММП, используют три асимптотически эквивалентных теста:

- Тест Вальда: оценивается только модель без ограничений, проверяется, насколько оценки далеки от ограничений с учётом их точности.
- Тест отношения правдоподобия: оцениваются обе модели, сравниваются значения ln L.
- Тест множителей Лагранжа (скор-тест): оценивается только модель с ограничениями, проверяется, насколько градиент правдоподобия отличается от нуля в этой точке.

Все три имеют асимптотически $\chi^2(q)$. В линейной модели при нормальных ошибках выполняется неравенство $W \geq LR \geq LM$, поэтому в конечных выборках выводы могут различаться. Многие диагностические тесты (Бройша–Пагана, Бройша–Годфри, Уайта) — это LM-тесты: они удобны тем, что требуют оценить только исходную модель и простую вспомогательную регрессию.

15.3. Цензурированная зависимая переменная: модель Тобит

Пусть y наблюдается только при положительных значениях, а остальные записываются как ноль. Пример: расходы домохозяйства на автомобили за год — у многих ноль, у остальных положительная сумма. Латентная модель:

$$y^* = x^\top\beta + \varepsilon,\ \varepsilon \sim N(0, \sigma^2),\ y = \max(0, y^*).$$

Если оценить МНК только по положительным наблюдениям или по всей выборке с нулями, оценки будут смещены. Правдоподобие Тобит-модели складывается из двух частей: для нулей — вероятность $\Phi(-x^\top\beta/\sigma)$, для положительных — плотность $(1/\sigma)\varphi((y - x^\top\beta)/\sigma)$.

Интерпретация требует аккуратности. Коэффициент β — эффект на латентную y*. Эффект на наблюдаемое среднее $E(y \mid x)$ равен $\beta \cdot \Phi(x^\top\beta/\sigma)$, то есть меньше по модулю. Сильное предположение модели: один и тот же механизм определяет и то, будет ли у положительной, и её величину.

15.4. Самоотбор: модель Хекмана

Зарплата наблюдается только у работающих, а решение работать зависит от ненаблюдаемых характеристик, которые влияют и на зарплату. Модель из двух уравнений:

$$\text{уравнение отбора: } s^* = z^\top\gamma + u, \text{ работает если } s^* > 0;$$
$$\text{уравнение интереса: } y = x^\top\beta + \varepsilon, \text{ наблюдается только при } s = 1.$$

Если $\mathrm{Corr}(u, \varepsilon) = \rho \neq 0$, то $E(y \mid x, s = 1) = x^\top\beta + \rho\sigma_\varepsilon \cdot \lambda(z^\top\gamma)$, где $\lambda(t) = \varphi(t)/\Phi(t)$ — обратное отношение Миллса. Двухшаговая процедура Хекмана: пробит для отбора, расчёт $\hat{\lambda}_i$, затем МНК y на x и $\hat{\lambda}$ по работающим. Значимый коэффициент при $\hat{\lambda}$ говорит о самоотборе.

Для надёжной идентификации в z желательно иметь хотя бы одну переменную, которой нет в x (например, число маленьких детей влияет на решение работать, но

не на зарплату при работе). Без такого исключающего ограничения модель держится только на нелинейности λ, и оценки бывают неустойчивыми.

15.5. Прогнозирование

Точечный прогноз при новых значениях x_0: $\hat{y}_0 = x_0^T b$. Различают две дисперсии.

Дисперсия прогноза среднего значения $E(y \mid x_0)$:

$$\mathrm{Var}(x_0^T b) = \sigma^2 \cdot x_0^T (X^T X)^{-1} x_0.$$

Дисперсия прогноза индивидуального значения y_0, включающая собственную ошибку нового наблюдения:

$$\mathrm{Var}(y_0 - \hat{y}_0) = \sigma^2 \cdot (1 + x_0^T (X^T X)^{-1} x_0).$$

Отсюда интервал прогноза для индивидуального значения всегда шире доверительного интервала для среднего, и при большой выборке он не сужается до нуля: остаётся неустранимая ошибка σ^2. В парной регрессии $x_0^T (X^T X)^{-1} x_0 = 1/n + (x_0 - \bar{x})^2 / \Sigma (x_i - \bar{x})^2$, поэтому интервалы расширяются по мере удаления x_0 от среднего. Экстраполяция далеко за пределы наблюдавшихся значений x даёт широкие интервалы и, кроме того, рискованна содержательно: линейность могла выполняться только в наблюдавшемся диапазоне.

Если зависимая переменная в логарифмах, наивный прогноз $\exp(\ln \hat{y})$ систематически занижает среднее. При нормальных ошибках исправленный прогноз равен $\exp(\ln \hat{y} + s^2/2)$. Более устойчивый к ненормальности вариант — поправка Дуана (smearing): умножить $\exp(\ln \hat{y})$ на среднее значение $\exp(e_i)$.

15.6. Проверка качества прогноза

Качество модели для прогноза оценивают вне обучающей выборки. Типичные метрики:

$$\mathrm{RMSE} = \sqrt{\Sigma (y_t - \hat{y}_t)^2 / m},\ \mathrm{MAE} = \Sigma |y_t - \hat{y}_t| / m,\ \mathrm{MAPE} = (100/m)\ \Sigma |(y_t - \hat{y}_t)/y_t|.$$

RMSE сильнее штрафует большие ошибки, MAE устойчивее к выбросам, MAPE удобна для сравнения рядов разного масштаба, но не определена при нулевых значениях и несимметрична.

Для временных рядов нельзя перемешивать наблюдения при разбиении на обучение и тест, как делают в обычной кросс-валидации. Используют скользящее или расширяющееся окно: модель оценивается на данных до момента t, прогнозирует t + h, окно сдвигается. Так имитируется реальная ситуация, когда будущее неизвестно. Простые эталоны для сравнения — наивный прогноз (завтра как сегодня) и сезонный наивный прогноз (как год назад). Сложная модель, не обыгрывающая наивный прогноз, бесполезна.

Тест Диболда–Мариано позволяет проверить, значимо ли различается точность двух прогнозов: строится ряд разностей функций потерь $d_t = L(e_{1t}) - L(e_{2t})$ и проверяется, равно ли нулю его среднее, с HAC-оценкой дисперсии.

15.7. Связь с машинным обучением

Многие понятия эконометрики имеют прямые аналоги в ML, но акценты разные. В ML главная цель — точность прогноза на новых данных, поэтому смещение допустимо, если оно снижает дисперсию (регуляризация, ансамбли). В эконометрике часто

важна интерпретируемая и несмещённая оценка конкретного параметра, потому что по ней принимаются решения о политике.

- Гребневая регрессия: $b = (X^TX + \lambda I)^{-1}X^Ty$. Решает проблему мультиколлинеарности ценой смещения к нулю.
- Лассо: минимизация $RSS + \lambda\Sigma|\beta_j|$. Обнуляет часть коэффициентов, то есть производит отбор переменных. Но отобранные лассо переменные нельзя затем «честно» проверять обычными t-тестами на тех же данных.
- Двойное машинное обучение (double/debiased ML) соединяет обе традиции: гибкие ML-модели используются для очистки y и интересующего регрессора от влияния многих контрольных переменных, а затем, как в теореме Фриша–Во–Ловелла, параметр оценивается регрессией остатков на остатки. Чтобы избежать переобучения, используется кросс-фиттинг: модели обучаются на одной части выборки, а остатки считаются на другой.

Общий вывод: регрессия — это одновременно и простейшая модель машинного обучения, и инструмент причинного анализа, но во втором качестве она требует гораздо больше внимания к предпосылкам.